考えるAIと物理 —— 第 1 回

AI・計算 × 物理の境界を、点でなく線で辿る

c はどこにでもいる

換算係数と、その三つの形 —— 一次・二次・対数

2026-10-19 ／ 出発点：ES（進化戦略）を「無限次元の逆伝播」と読む小論。数値はすべてこの日に手元で回したもの

進化戦略（ES）の式を眺めていたら、「並列にたくさん試すこと」と「順番にたくさん試すこと」が交換できそうに見えた。辿っていくと、熱方程式、統計力学、拡散モデル、くりこみ群、そして特殊相対論の光円錐まで、同じ形の換算が何度も出てきた。新しい発見を探すのではなく、この換算たちを一枚の地図にする。

00 先に仕分け表

話が面白くなるほど「そんな夢みたいな話ある？」と疑うべきなので、物語の前に全部の線の格付けを置く。

線	格付け	この日の検証
ES の勾配 = ガウスでぼかした損失の勾配（Stein の補題）	教科書	4 桁一致
ガウスぼかし = 熱方程式を時間 $\sigma^2/2$ 進めること	教科書	4 桁一致、半群性 7×10^{-9}
ES/SGD のゆらぎの強さは η/N だけで決まる（温度）	教科書（SDE 極限）	定常損失が一致
谷を越える時間はクラマースの式 $e^{\Delta U/T}$	教科書	予言の 15% 以内
集団サイズ N = 逆温度（Sella–Hirsh 2005）	教科書（集団遺伝学）	—
自然選択 1 世代 = 拡散モデルのノイズ除去 1 段（Lande = Tweedie）	実在、比較的新しい整理	4 桁一致
CNN の深さ：stride 1 は σ^2、stride 2 は $\ln \sigma$	既知（Luo ら 2016 ほか）	綺麗に一致
CNN の層 ↔ くりこみ群（Mehta–Schwab 2014）	実在するが解釈は係争中	イジングの流れのみ
大バッチ学習の双曲線 = 光円錐座標、B_{crit} = c	語り（式は McCandlish 2018）	半分だけ：双曲線は当たらず
換算の形は「一次・二次・対数」の三つで足りる	語り	—

色：教科書 ／ 実在するが新しめ・係争中 ／ この地図の語り ／ 数値合わせ（今回は該当なし）

01 換算係数とは何か

核心

二つの量が一定のレートで交換できるとき、必ず換算係数が一つ現れ、物理を変えない伸縮の対称性が一つ生まれる。物理ではその係数を c、ħ、k_B、D と呼び、自然単位系では 1 と置いて消す。換算は何も予言しない。ただ、別の物差しで測っても同じだと言っているだけで、計算がたまに楽になる。

この日に出てきた「c」たちを並べるとこうなる。右端の列が本体で、単位の付いた量は舞台装置にすぎない。

換算	係数	交換される二つ	形	不変な無次元量
$x = ct$	c	時間 ↔ 長さ	一次	x/ct
$\sigma^2 = 2Dt$	D	時間 ↔ 長さ²	二次	σ^2/Dt
$T \propto \eta/N$	η/N	世代数 ↔ 集団の大きさ	一次（積）	$N \cdot T$
N = 逆温度	k_B 相当	集団の大きさ ↔ 温度	—	Ns
$\beta = it/\hbar$	$\hbar$	時間 ↔ 逆温度	—	$Et/\hbar$
$\ell = \ln \sigma$	$\ln 2$/層	深さ ↔ スケール	対数	$\ln(\xi/a)$
B_{crit}	B_{crit}	ステップ数 ↔ サンプル数	一次（積）	B/B_{crit}

02 二次の換算：ぼかし幅の二乗は時間

ES は、パラメータ θ にノイズ $\sigma\epsilon$ を足して損失を測り、ノイズとの相関から下る方向を決める。微分は一度も計算しない。それでも Stein の補題（ガウスの部分積分）により

$$\frac{1}{\sigma}\,\mathbb{E}_\epsilon[L(\theta+\sigma\epsilon)\,\epsilon] \;=\; \nabla L_\sigma(\theta), \qquad L_\sigma = L * \mathcal{N}(0,\sigma^2)$$

が成り立つ。そしてガウスでぼかすことは、熱方程式を解くことそのものである。

$$\frac{\partial L_\sigma}{\partial(\sigma^2/2)} = \Delta L_\sigma$$

ぼかし幅 σ は長さだが、その二乗が時間として振る舞う。左辺は L が微分できなくても定義できる。段差（崖）のある地形でも ES は有限の「坂」を返す。

計算 **ES の勾配 vs 熱方程式の解の勾配**

地形 $L = |\sin 3x| + 0.5\,[x > 0.4]$（折れ目と段差あり、勾配は存在しない）。$\sigma = 0.1$、熱方程式は差分法で時間 0.005 まで。

x	ES（微分なし）	熱方程式
-1.0	0.9867	0.9861
-0.5	-0.2029	-0.2029
0.4（段差）	3.0320	3.0316
0.7	-1.4227	-1.4225
1.2	2.1998	2.1973

「$\sigma = 0.1$ でぼかしてから残りをぼかす」と「最初から $\sigma = 0.3$」の差は最大 6.7×10^{-9}。分散が足し算になる＝時間が足し算になる。

同じ二次が CNN の受容野にも出る

ストライド 1 の畳み込みを L 層重ねると、出力 1 点が効いている入力の範囲（実効受容野）は、中心極限定理でガウスに近づき、半径は $\sqrt{L}$ で伸びる。深さは熱方程式の時間である。

計算 **ランダム CNN（3×3、16ch、He 初期化、8 回平均）**

層数 L	1	2	4	8	16	32
半径 r（線形）	0.78	1.30	2.02	3.12	4.51	6.37
半径 r（ReLU）	0.81	1.28	1.92	3.07	4.50	6.41
r / √L	0.81	0.91	0.96	1.09	1.13	1.13

二次の換算は「温度」も運ぶ

ES や SGD の更新を、小さな歩幅 η で何歩も重ねる極限で見ると、確率微分方程式になる。

$$d\theta = -\nabla L_\sigma \, dt + \sqrt{\eta/N}\, \Sigma^{1/2}\, dW$$

ゆらぎを決めるのは η/N だけ。集団を大きくする（空間）ことと、歩幅を小さくして世代を重ねる（時間）ことが交換できる。これはランジュバン方程式で、η/N は温度にあたる。

計算 **定常状態の損失（10 次元二次関数、片側 ES）**

η	N	η/N	⟨L⟩
0.001	1	0.001	0.218
0.002	2	0.001	0.207
0.004	4	0.001	0.221
0.008	8	0.001	0.215
0.001	4	0.00025	0.048
0.004	1	0.004	1.12

温度なら、谷を越える時間はクラマースの式 $\tau \approx \frac{2\pi}{\sqrt{U''_{\min}|U''_{\max}|}}\, e^{\Delta U/T}$ に従うはず。二重井戸 $(x^2-1)^2$、$\sigma = 0.3$ で $\Delta U/T = 5.6$ のとき：

η	N	測定 τ	クラマース
0.004	1	359 ± 8	415
0.008	2	362 ± 8	415
0.016	4	340 ± 7	415

補足：ぼかしは障壁を溶かす

二重井戸をぼかすと解析的に $L_\sigma = x^4 + (6\sigma^2 - 2)x^2 + \text{const}$。障壁は $(1-3\sigma^2)^2$ に下がり、$\sigma \geq 1/\sqrt{3}$ で消える。一方 ES の推定ノイズは $T \propto 1/\sigma^2$ で系を熱する。抜けにくさ $\Delta U/T \propto \sigma^2(1-3\sigma^2)^2$ は $\sigma = 1/3$ で最大になる —— というのはこの地形での予言で、まだ測っていない。

03 温度の線：ES、自然選択、拡散モデル

集団遺伝学では、集団サイズ N がそのまま逆温度になることが厳密に示されている（Sella–Hirsh 2005）。Kimura の拡散近似が時間を「$2N$ 世代」単位で測るのも同じ換算である。そして自然選択の 1 世代は、拡散モデルの Tweedie の公式と同じ式になる。

$$\underbrace{\Delta\bar{z} = \frac{\mathrm{Cov}(w, z)}{\bar{w}} = \sigma^2 \nabla \ln \bar{w}}_{\text{Price / Lande}} \quad \Longleftrightarrow \quad \underbrace{\mathbb{E}[x_0 \mid x] - x = \sigma^2 \nabla \log p_\sigma(x)}_{\text{Tweedie}}$$

適応度 w をデータの確率密度 p と読み替えれば同じ計算。ES との違いは log と平均の順序だけで、ES は平均エネルギー $\langle L \rangle$ を、選択は自由エネルギー $-\log\langle e^{-L} \rangle$ をぼかしている。

計算 **選択 1 世代の移動 ／ 拡散モデルのスコア ／ ES（$w = e^{-3(x^2-1)^2}$、$\sigma = 0.4$）**

集団の中心 z	選択（MC）	Tweedie	ES
-1.5	0.4383	0.4384	4.98
-0.6	-0.2213	-0.2213	-0.18
0.3	0.2989	0.2985	0.25
0.9	+0.0262	+0.0264	-0.50

$z = 0.9$ では選択は谷底 $x \approx 1$ へ、ES は平均エネルギーの最小点 $x = \sqrt{1 - 3\sigma^2} \approx 0.72$ へ向かう。二つのぼかし方で「最適な場所」がずれる。適応度の強さ β を 0.3 まで弱めると両者はほぼ一致する：ES は選択の高温極限。

04 対数の換算：深さはスケールの対数

CNN で毎層解像度を半分にすると、受容野は倍々で伸びる。くりこみ群の「時間」は $\ell = \ln(\text{スケール})$ なので、深さは ℓ そのものになる。

計算 **stride 2 の CNN（ReLU）**

層数 L	1	2	3	4	5	6
$\log_2$ r	-0.31	0.88	2.02	3.04	4.02	5.05

ImageNet 用の CNN がだいたい 5 段でダウンサンプリングするのは $\log_2(224/7) = 5$ だから。くりこみ群で格子間隔 a から相関長 ξ まで行く段数 $\ln(\xi/a)$ と同じ量で、必要な深さを決めているのは無次元量 $\ln(\text{物体}/\text{画素})$ である。

層を通して流れるもの

計算 **2 次元イジング、2×2 多数決 = 1 層（256² → 8²）、隣接スピン相関**

```
T = 0.9 Tc :  0.857 → 0.910 → 0.963 → 0.993 → 0.999 → 1.000   秩序の固定点へ
T = Tc     :  0.701 → 0.682 → 0.668 → 0.642 → 0.610 → 0.508   ほぼ留まる
T = 1.1 Tc :  0.555 → 0.453 → 0.335 → 0.206 → 0.103 → 0.059   無秩序の固定点へ
```

Tc でもゆっくり減るのは、多数決則が厳密なくりこみでないことと、格子が有限であることによる。0.9 Tc は揃えた初期状態から（ランダム初期だと磁区が残って乱れた）。

深い層に残るのは画素ではなく、粗視化しても生き残る量（relevant な結合）である。

05 一次の換算：光円錐の形

第2回 の η/N を、マクロな時間 $t = \eta T$（T はステップ数）と温度 $\tau = \eta/N$ を固定して見直すと、

$$N \cdot T = t/\tau \;=\; \text{不変}, \qquad N \to \lambda N,\;\; T \to T/\lambda,\;\; \eta \to \lambda\eta$$

という伸縮が物理を変えない。これは特殊相対論のローレンツ変換を光円錐座標
$u = ct + x,\; v = ct - x$ で書いた形（$u \to \lambda u,\; v \to v/\lambda,\; uv$ が不変）と同じで、$\ln \lambda$ はラピディティにあたる。群はどちらも SO(1,1)。

「光速」にあたるものもある。大バッチ学習の経験則（McCandlish ら 2018）は、目標損失までのステップ数 S と総サンプル数 E について

$$(S - S_{\min})(E - E_{\min}) = S_{\min} E_{\min}$$

$$S - S_{\min} = S_{\min} e^{-\varphi}, \qquad E - E_{\min} = E_{\min} e^{\varphi}, \qquad \varphi = \ln \frac{B}{B_{\text{crit}}}$$

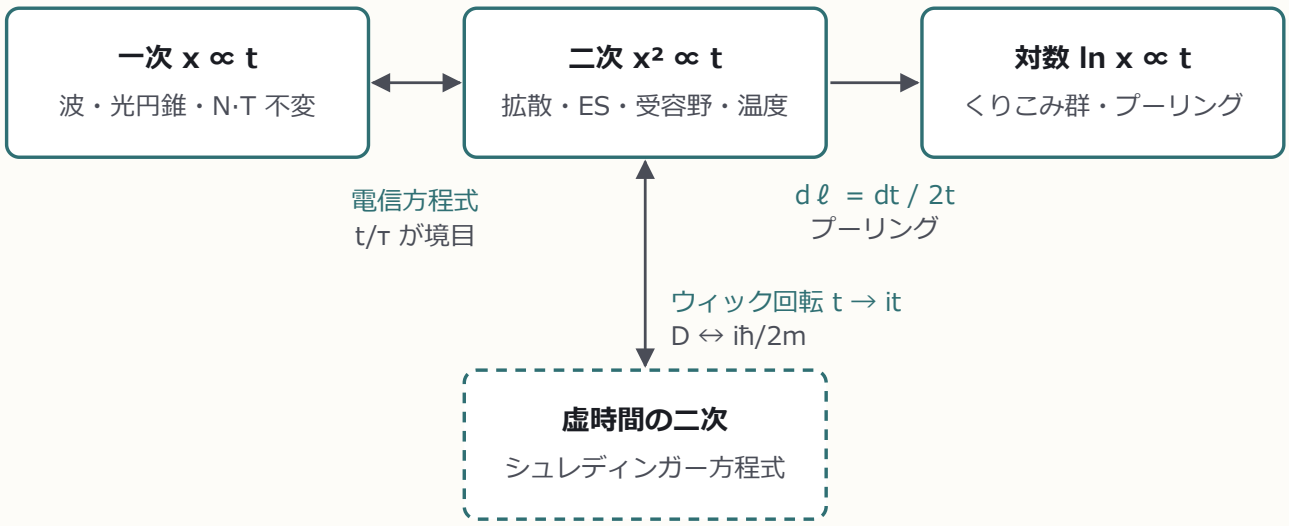
と書ける。余分なステップと余分なサンプルが光円錐座標、バッチサイズの比の対数がラピディティ、B_{crit} が c。これ以上並列にしてもステップ数は減らない。

計算 **ES で検証（各 N で η を最適化、目標 L < 0.3）—— 半分だけ成功**

N	1	4	16	64	256	1024	4096
S	950	354	82	26	9	4	3
E = NS	950	1416	1304	1696	2304	4096	12288

N ≲ 16 では E がほぼ一定（空間と時間が等価に交換できる）。N ≈ 40 を超えると E が増え始め、「速度の上限」の折れ曲がりはある。ただし双曲線そのものは当てはまらなかった。大きな N では数ステップで届く簡単な問題なので、ステップの離散性が効いている。

06 形どうしをつなぐ線



換算の三つの形と、それらを結ぶ線。点線の箱は「形は二次のまま、時間が虚数」

- 二次 → 対数：$\ell = \frac{1}{2}\ln t$ より $d\ell = dt/2t$。プーリングは拡散の時計を対数の時計に掛け替える。第4回 の CNN で、同じ網が stride 1 では二次、stride 2 では対数に切り替わった。
- 一次 ↔ 二次：電信方程式 $\tau\,\partial_t^2 u + \partial_t u = D\nabla^2 u$。$t \ll \tau$ では速さ $\sqrt{D/\tau}$ でまっすぐ進み（一次）、$t \gg \tau$ では拡散する（二次）。境目は無次元量 t/τ。持続性のあるランダムウォークと同じ（教科書、この日は未検証）。
- 二次 ↔ 虚時間の二次：熱方程式で $t \to it$ とするとシュレディンガー方程式。虚時間は逆温度 $\beta = it/\hbar$ で、第3回 の「温度」の線とここでつながる。形（$x^2 \propto t$）は変わらず、時間の方向が回る。

07 正直な線

どこで線が切れるか

- **新しくはない。** この地図の線は、Stein、Kramers、Kimura、Sella–Hirsh、Lande、Tweedie、Luo、Mehta–Schwab、McCandlish と、ほぼ全部すでに誰かが引いている。分野をまたぐと見えにくいだけ。価値は点ではなく、つないだ地図の方にある。
- **η/N の交換は η が無限小の極限でだけ厳密。** 有限の η、B_{crit} 超えでは崩れる。
- **光円錐との並行は窓の中だけ。** 特殊相対論の対称性はどのラピディティでも厳密だが、こちらは下限 $N \geq 1$、上限 B_{crit} と安定性に挟まれた近似的な対称性。計量や因果構造にあたるものは無い。
- **ここでの c は特殊相対論の換算係数としての c。** 宇宙年齢で長さを測る「c·t = const」の単位の約束とは別の主張なので混ぜない。共通するのは態度の方 —— 換算は何も予言せず、計算をたまに楽にするだけ。
- **CNN ↔ くりこみ群は、何を残すかの基準が違う。** くりこみ群は長距離の物理を、CNN は学習ラベルを基準に残す。線形のぼかしだけなら何層重ねても一つのガウスに潰れる。
- **ES と自然選択は同一ではない。** 平均エネルギーと自由エネルギーの差（Jensen の差）があり、適応度が強いほど広がる。

まとめ

- 二つの量が一定のレートで交換できると、換算係数と伸縮の対称性が一つずつ現れる。c はその一例にすぎない。
- 換算の形は **一次**（$x \propto t$）・**二次**（$x^2 \propto t$）・**対数**（$\ln x \propto t$）。形を見ると裏で何が起きているか（進行・拡散・スケール不変）が分かる。
- ES・SGD・自然選択・拡散モデル・CNN・くりこみ群は、この三つの形と、それらをつなぐ線（$d\ell = dt/2t$、電信方程式、ウィック回転）で一枚の地図に載る。
- 不変な無次元量：η/N、Ns、$\Delta U/T$、$\ln(\xi/a)$、B/B_{crit}、t/τ。

次に引く線の候補 双曲線を難しい地形で当てに行く ／ RBM = くりこみ群（Mehta–Schwab）を実際に計算する ／ 拡散モデル → Schrödinger bridge → 経路積分 ／ エルゴード性の破れ → スピングラス → 損失地形の局所解

1. Salimans ら (2017) Evolution Strategies as a Scalable Alternative to RL ／ Nesterov & Spokoiny (2017) Random gradient-free minimization
2. Kramers (1940) ／ Kimura (1962) 固定確率の拡散近似 ／ Sella & Hirsh (2005) PNAS「集団遺伝学と統計力学の対応」
3. Price (1970) ／ Lande (1976, 1979) ／ Efron (2011) Tweedie's formula ／ Zhang ら (2024) Diffusion Models are Evolutionary Algorithms
4. Luo ら (2016) Understanding the Effective Receptive Field ／ Mehta & Schwab (2014) An exact mapping between the variational RG and deep learning
5. McCandlish ら (2018) An Empirical Model of Large-Batch Training ／ Goyal ら (2017) ／ Smith & Le (2018)
6. 数値実験のスクリプト：`scripts/`（es_st / kramers / heat / selection / erf / ising_rg / hyperbola）