AI・計算 × 物理の境界を、点でなく線で辿る

# LLM は物理で書ける

順伝播は冷却、逆伝播は時間反転、attention はボルツマン —— 四行で言えること

2026-10-20 ／「LLM と構造が似ている」を、比喩でなく定理の形で。検証は付録に回した

**四行の要約**

1. **逆伝播は、時間を逆向きに走る物理そのもの。** 1950 年代の最適制御の随伴方程式と同じで、順方向が位置、逆方向が運動量。両方を合わせたハミルトニアンは保存する。
2. **逆伝播の信号は、物理でいう「応答」。** softmax の微分は出力のゆらぎ（共分散）に等しい。揺動散逸定理が一個の softmax について厳密に成り立つ。
3. **LLM はすでにボルツマン分布で動いている。** 温度は文字どおり温度。attention の一回はホップフィールド網の一更新で、エネルギーは必ず下がる。層を重ねるとトークンは凝集し、文脈内学習は順伝播の中の勾配降下である。
4. **情報の側は、減ることしかできない。** 層を通るたびに入力の情報は減る（データ処理不等式）。予測に効かない記憶は、熱のコストになる（学習の熱力学）。

ここまでの線を LLM に当てると、どれも既に名前が付いていた。新しい主張はしない。代わりに、四行のそれぞれを小さな計算で確かめて、どこまで厳密でどこから崩れるかを書いておく。

## 00 先に仕分け表

| 線 | 格付け | この日の検証 |
|---|---|---|
| 逆伝播 = 随伴方程式、H = a·f が保存 | 教科書（Pontryagin 1956、Linnainmaa 1970） | H の変動 $10^{-4}$、勾配一致 $7\times10^{-4}$ |
| softmax の微分 = 共分散（揺動散逸） | 教科書 | 恒等式 $10^{-11}$、サンプリングで $10^{-4}$ |
| attention = 現代ホップフィールドの一更新 | Ramsauer ら 2020（定理つき） | エネルギー単調、$\beta$ で記憶が溶ける |
| 深さとともにトークンが凝集 | Geshkovski ら 2023 | 64 → 1 クラスター、$\beta$ で遅れる |
| 文脈内学習 = 勾配降下 1 歩 | von Oswald ら 2023 | 構成は厳密 $10^{-16}$、学習でも GD 1 歩と同じ精度 |
| データ処理不等式、学習の熱力学 | 教科書 ／ Still ら 2012 | —（計算なし） |
| 「順伝播 = 冷却、逆伝播 = 時間反転、揺動散逸が両者をつなぐ」 | この地図の語り | 部品ごとには確認、全体としては未 |

## 01 逆伝播は時間反転

層を時間とみなす（第2回）と、ネットワークは微分方程式 $\dot{x} = f(x, \theta)$ で、損失は終端の $L(x(T))$。随伴変数 $a = \partial L/\partial x$ は

$$\dot{a} = -\left(\frac{\partial f}{\partial x}\right)^{\top} a, \qquad a(T) = \nabla L, \qquad \frac{dL}{d\theta} = \int_0^T a^{\top} \frac{\partial f}{\partial \theta}\, dt$$

に従い、これが逆伝播である。$x$ と $a$ はハミルトニアン $H = a \cdot f(x, \theta)$ の正準方程式の組になり、$\theta$ が時間によらなければ $H$ は保存する。

> 計算 **4 次元の $\dot{x} = \tanh(Wx + b)$、RK4 で 2000 歩、逆向きに随伴を積分**
>
> H = a·f を t = 2.0 から 0 まで 6 点で：3.73533 → 3.73532 → 3.73528 → 3.73518 → 3.73501 → 3.73479（変動 $1.5\times10^{-4}$、離散化誤差の程度）。dL/dW を自動微分（離散の逆伝播）と随伴の積分で比べると相対差 $7\times10^{-4}$。

見た目は違っても、自動微分の逆伝播と、物理の随伴方程式は同じ計算である。最初に書いた版では随伴の時間の向きを間違え、H が 20% 流れた。符号ひとつで保存が壊れる、というのがこの定理の中身そのものだった。

## 02 逆伝播の信号はゆらぎ

温度 T の softmax $p_i = e^{h_i/T}/Z$ について

$$\frac{\partial p_i}{\partial h_j} = \frac{1}{T}\,p_i(\delta_{ij} - p_j) = \frac{1}{T}\,\mathrm{Cov}(\mathbf{1}_i, \mathbf{1}_j)$$

左辺は「ロジットを押したときの出力の応答」で、逆伝播が出力層で運ぶ量。右辺は「出力のゆらぎ」。これは揺動散逸定理の一番小さい形で、第3回の定理 1（対数微分の恒等式）の子どもである。

> 計算 **8 トークン、観測量 f(トークン) をランダムに取り、応答は微分で、ゆらぎは 200 万サンプルから**
>
> | T | max \|応答 − Cov/T\| | 応答の大きさ |
> |---|---|---|
> | 1.0 | $2.9\times10^{-4}$ | 0.26 |
> | 0.5 | $8.4\times10^{-4}$ | 0.39 |
>
> 差はサンプリングの統計誤差の程度。恒等式そのものは $4\times10^{-11}$ で成立。

## 03 attention はボルツマン

**温度。** LLM の「温度」は比喩ではない。ロジットが −エネルギー、softmax がボルツマン分布、サンプリング温度が $k_B T$ で、perplexity は $e^{\text{エントロピー}}$。第1回の「温度」の線は、LLM では最初から部品に入っている。

**attention = ホップフィールド。** 記憶パターン $X$（鍵 = 値）に対して、エネルギー $E(\xi) = -\frac{1}{\beta}\ln\sum_i e^{\beta\, x_i\cdot\xi} + \frac{1}{2}|\xi|^2$ を定めると、$\xi \leftarrow X^\top \mathrm{softmax}(\beta X\xi)$ はその一更新で、E は単調に下がる（Ramsauer ら 2020）。これは attention の式そのものである。

計算 **64 次元に 20 パターン、ランダムな初期値 200 個から反復**

| β | 収束まで | E 単調 | 最近接パターンとの重なり | 到達した固定点の数 |
|---|---|---|---|---|
| 1 | 9.7 | はい | 0.42 | 1 |
| 4 | 21.3 | はい | 0.45 | 1 |
| 16 | 6.0 | はい | 1.00 | 20 |
| 64 | 3.2 | はい | 1.00 | 20 |

$\beta$ が小さい（高温）と全部の記憶が溶けて平均一つに落ちる。$\beta$ が大きい（低温）と 20 個の記憶がそれぞれ取り出せる。相転移の境目は $\beta \approx 4$〜16 の間。

**深さ = 時間、トークン = 粒子。** 自己注意だけの層を重ねると、トークンは互いに引き合って凝集する（Geshkovski ら 2023）。

計算 **球面上の 64 トークン、16 次元、残差つき自己注意を L 層。クラスター数（cos > 0.99 で同一視）**

| β | L=0 | 10 | 20 | 50 | 100 | 200 | 500 |
|---|---|---|---|---|---|---|---|
| 1 | 64 | 64 | 64 | 11 | 1 | 1 | 1 |
| 4 | 64 | 64 | 64 | 58 | 1 | 1 | 1 |
| 9 | 64 | 64 | 64 | 62 | 50 | 24 | 6 |

最後は一点に潰れる。$\beta$ が大きいほど途中の準安定なクラスターが長持ちする —— 第1回のイジングの流れ、第4回の局所解と同じ構造。

**文脈内学習 = 勾配降下。** 線形 attention に特定の重みを入れると、文脈中の (x, y) に対する最小二乗の勾配降下を一歩、順伝播の中で実行する（von Oswald ら 2023）。

計算 **4 次元の線形回帰、文脈 16 点**

構成した重みでは attention の出力と GD 一歩の予測が一致（差 $7\times10^{-16}$）。重みをゼロから学習させた線形 attention の試験 MSE は 0.961、最適な歩幅の GD 一歩は 0.952、最小二乗の厳密解は 0.000、ゼロ予測は 4.08。学習した一層は、GD 一歩の精度に収束し、それを超えない。

## 04 情報は減ることしかできない

層は $X \to h_1 \to h_2 \to \cdots$ のマルコフ連鎖なので、$I(X; h_{l+1}) \le I(X; h_l)$（データ処理不等式）。学習は情報を増やす操作ではなく、捨てる順番を選ぶ操作である。第1回のくりこみ群と同じ向きで、違うのは何を残すかの基準だけだった。

学習の熱力学（Still ら 2012）では、系が過去について抱えている情報 $I_{\text{mem}}$ のうち、未来の予測に効かない分 $I_{\text{mem}} - I_{\text{pred}}$ が散逸の下限になる。LLM に当てると、文脈のうち次の単語に効かない部分を覚えておくことが、そのまま熱のコストになる。第4回の Landauer（1 ビット消すのに $kT\ln 2$）の、学習版である。ここは計算していない。

## 05 換算表

| LLM の部品 | 物理での名前 | 回 |
|---|---|---|
| ロジット ／ 温度 ／ perplexity | −エネルギー ／ $k_BT$ ／ $e^S$ | 1 |
| softmax の微分 | 共分散、感受率（揺動散逸） | 3, 5 |
| attention 一回 | ホップフィールドのエネルギー降下一歩 | 5 |
| 層 | 時間、虚時間 | 2 |
| トークン | 球面上の相互作用する粒子 | 5 |
| 順伝播 | 冷却、凝集 | 1, 5 |
| 逆伝播 | 随伴方程式、時間反転、運動量 | 5 |
| 文脈内学習 | 順伝播の中の勾配降下 | 5 |
| 学習率 / バッチ | 温度 $\eta$ /N | 1 |

## 06 正直な線

**どこで線が切れるか**

- **揺動散逸が厳密なのは softmax 一個まで。** ネットワーク全体では、応答は線形近似、ゆらぎは平衡でない。「全体で成り立つか」は測っていない。
- **凝集の計算は重みのない自己注意。** 学習済みの LLM で隠れ状態の異方性が深さとともに増すことは知られている（Ethayarajh 2019）が、今日は確認していない。
- **文脈内学習 = GD は線形 attention の話。** softmax attention と MLP を含む本物の Transformer で何をしているかは研究が続いている。
- **H の保存は $\theta$ が層によらないとき。** 普通のネットワークは層ごとに重みが違うので、H は保存せず、各層で $\partial H/\partial \theta_l$ の分だけ変わる。それがちょうど勾配である。
- **四行目は計算なし。** 学習の熱力学を LLM で測るには、文脈の情報量を推定する必要があり、今日の道具では届かない。
- **新しくはない。** 全部、引用先がある。新しいのは並べ方と、第1〜4回の線がそのまま通ることの確認だけ。

**まとめ**

- 逆伝播は随伴方程式で、H = a·f が保存する時間反転。
- softmax の微分は共分散。逆伝播の信号は、出力のゆらぎを運んでいる。
- attention はホップフィールドの一更新、層は時間、トークンは凝集する粒子、文脈内学習は順伝播の中の勾配降下。
- 情報は層を通るたびに減る。予測に効かない記憶は熱になる。

**次に引く線の候補** 小さな Transformer を実際に学習させ、順方向の応答と逆方向の勾配の相関（揺動散逸）がどこまで合うかを測る ／ 学習済みモデルで深さとともに隠れ状態が凝集するか ／ 文脈の情報量を推定して、学習の熱力学の不等式を測る


1. Pontryagin ら (1956) ／ Kelley (1960)、Bryson (1961) ／ Linnainmaa (1970) ／ Chen ら (2018) Neural ODE
2. Ramsauer ら (2020) Hopfield Networks is All You Need ／ Geshkovski, Letrouit, Polyanskiy, Rigollet (2023) A mathematical perspective on Transformers
3. von Oswald ら (2023) Transformers learn in-context by gradient descent ／ Ethayarajh (2019)
4. Still, Sivak, Bell, Crooks (2012) Thermodynamics of prediction ／ Tishby & Zaslavsky (2015) 情報ボトルネック

5. スクリプト：`scripts/llm_lines.py`、出力 `scripts/llm_lines_out.txt`